

无人机低空航拍图像语义分割

技术报告 | HyperSeg-UAV

报告日期：2026 年 9 月 20 日

一、算法概述

本项目面向无人机低空航拍图像的像素级地物识别，围绕目标尺度差异大、场景组成复杂、类别分布不均衡及细小目标易漏分等问题，构建以 HyperSeg 为主线的语义分割方案。模型输入 RGB 图像，输出背景、建筑、道路、水体、裸地、植被、农田和车辆八类有效地物，忽略标签不参与主要监督与评价。算法采用层次化视觉编码器提取多尺度特征，通过场景上下文生成特征调制参数和尺度融合权重，再结合卷积解码器、语义预测头与边界辅助监督完成分割。基础版本采用 MiT-B3，增强实验将骨干替换为 Swin-L，并通过通道投影复用 HyperSeg 解码路径。训练结合随机缩放、场景与稀有类裁剪、复合损失和分组学习率，评估采用固定数据划分与全数据集混淆矩阵。已完成的 HyperSeg 骨干增强实验在 699 张有标注独立测试图像上取得 78.73% 的八类 mIoU。方案具备从训练、验证到掩码导出的完整流程，可为低空巡检、地表覆盖调查和农业场景分析提供像素级信息基础。

报告范围与成果口径

本文以项目自研 HyperSeg-UAV 单图监督分割路径为核心，按数据处理、算法设计、训练优化和验证交付展开。Swin-L 是该路径的骨干增强实现；Mask2Former 是参考对照。文中 78.73% 属于 Swin-L + HyperSeg (H3) 实验，不代表 MiT-B3 基础版本的成绩，也不是无标注比赛测试集的官方成绩。

成果依据为当前代码、固定划分及已下载日志。应用价值属于可支持的业务方向，尚无实际部署收益、端侧速度或官方竞赛排名记录。团队姓名及缺乏原始记录的早期日期保留待补充。

二、实现方案

2.1 任务定义与数据组织

主数据集为 low_altitude_2026。本地核对有标注图像及掩码各 6996 个 PNG 文件，固定划分包含训练 5598 张、验证 699 张、测试 699 张，三个 ID 集合两两无交集。训练目录是有标注样本的存放位置，具体用途由划分清单决定。文件名互斥并不能证明不存在相邻航拍帧或同场景相关性。

数据部分	数量	用途
有标注训练划分	5598	参数学习与训练增强
有标注验证划分	699	选择最佳 checkpoint
有标注独立测试划分	699	最终离线评价，不参与选模
无标注比赛图像	500	导出提交掩码，不能计算 mIoU

标签 ID	类别	评价规则
0	Ignore / 忽略区域	真实标签为 0 的像素排除
1 / 2	Background / 背景; Building / 建筑	计入八类 mIoU
3 / 4	Road / 道路; Water / 水体	计入八类 mIoU
5 / 6	Barren / 裸地; Vegetation / 植被	计入八类 mIoU
7 / 8	Agricultural / 农田; Vehicle / 车辆	计入八类 mIoU

2.2 数据预处理与增强

训练从 0.5、0.75、1.0、1.25、1.5 中随机选择缩放比例，再进行随机裁剪；以默认 0.3 概率尝试包含至少三种有效类别或包含裸地、农田、车辆的区域。水平和垂直翻转概率均为 0.5，并叠加亮度、对比度及颜色扰动，以增加方向、尺度和成像条件的变化。

图像与标签共用几何变换参数，图像使用双线性插值，掩码使用最近邻插值，保持空间对齐及整数标签。基础数据集输出[0,1]浮点 RGB。H3 模型内执行 ImageNet 均值、标准差归一化，训练、评价和导出使用相同模型路径，避免重复标准化。

2.3 HyperSeg 模型设计

整体路径为：RGB 图像 → 四级编码特征 → 场景条件提取 → 各尺度动态调制 → 多尺度动态融合 → 低秩残差接口 → 卷积解码 → 语义与边界双头。场景向量同时驱动调制、融合及残差参数生成，实现逐图像的条件化处理。

模块	具体实现与作用
层次化编码器	基础版本 MiT-B3 输出[64,128,320,512]通道；H3 使用 Swin-L，再以四个 1×1 卷积对齐至相同通道。
场景条件提取	各尺度投影到 128 维，全局平均池化后拼接，经 MLP 得到 128 维场景向量。
动态调制	由场景向量生成每个尺度的 γ 与 β ，对 GroupNorm 后的特征进行有界缩放和平移。
动态融合	各尺度投影到 64 通道并对齐到最高特征分辨率，按场景生成的四个 softmax 权重加权求和。
解码与输出	两组 3×3 卷积、BatchNorm、GELU；9 通道语义头与 1 通道边界头；双线性上采样恢复输入尺寸。

动态调制定义为 $F'_i = \text{GN}(F_i) \times [1 + 0.15 \tanh(\gamma_i(c))] + 0.15 \tanh(\beta_i(c))$ 。其中 c 是场景向量，尺度系数限制条件参数幅度；零初始化使初始动态增量为零，初始输出为归一化特征。动态融合为 $F = \sum_i \text{softmax}(g(c))_i \times \text{Resize}(P_i(F'_i))$ 。

低秩接口由场景向量生成秩为 8 的下投影与上投影矩阵，以 0.1 缩放系数添加残差。该接口是实现中的结构组成，其有效训练和独立增益尚需进一步核验；不据此宣称已获得参数效率或精度提升。

2.4 多目标监督

$L = 0.55 L_{\text{focal-CE}} + 0.30 L_{\text{Dice}} + 0.025 L_{\text{rare}} + 0.10 L_{\text{boundary}}$ 。

Focal 交叉熵采用 $\gamma=1.5$ ，降低容易像素的贡献；Dice 对当前批次实际出现的有效类别求平均；稀有类项累加裸地、农田和车辆目标像素的负对数概率；边界项通过相邻标签差异构造目标并计算 BCE。主要损失在非 Ignore 像素上计算，当前训练不额外传入类别权重。边界头用于辅助训练，最终类别掩码由语义头产生。

2.5 模型训练与优化

MiT-B3 是 HyperSeg 基础骨干。为检验更强编码特征与既有动态解码路径的组合，H3 接入 ImageNet-22K 预训练 Swin-L，保留 64 通道融合及解码宽度。新增通道接口及下游模块重新初始化，不加载完整 Mask2Former 分割模型。以下参数来自 H3 实际运行配置与训练入口。

设置	H3 实际配置
裁剪 / 有效批量	512×512 / 2；梯度累积 1 次
训练预算 / 随机种子	160000 次优化器更新 / 3407
优化器	AdamW；weight decay=0.01；betas=(0.9,0.999)
学习率	骨干 1×10^{-5} ；投影与 HyperSeg 下游模块 1×10^{-4}
调度与梯度约束	Poly 衰减，power=0.9；全局梯度范数上限 1.0
精度与显存策略	FP32；启用骨干 gradient checkpointing
验证与选模	每 2800 次更新验证，结束时额外验证；按验证 mIoU 保存 best.pt
评价尺度	原始分辨率整图、batch=1、无 TTA

三、算法创新点

3.1 面向场景差异的条件化分割路径

在多尺度编码与解码之间引入场景上下文，使同一模型能够为不同图像生成调制参数和尺度融合权重。该设计将航拍场景组成信息显式引入特征处理，适用于道路、建筑群、植被与农田等组成差异明显的画面；实际增益需通过关闭调制、改为固定融合等受控实验量化。

3.2 面向尺度与类别差异的联合优化

多尺度特征融合保留较高分辨率细节并引入深层语义；训练侧结合场景 / 稀有类裁剪、Focal、Dice 和稀有类补充项，关注大面积常见地物与小面积目标之间的监督差异。边界辅助头增加相邻类别交界处的训练约束。上述策略构成项目的组合设计，不将其中通用方法宣称为首创。

3.3 可替换骨干的 HyperSeg 实现

通过明确的四级通道接口，使 MiT-B3 基础实现与 Swin-L 增强实现共用 HyperSeg 动态解码路径。H3 保持融合及卷积解码宽度不变，支持后续以统一协议研究骨干与动态模块的贡献。当前完成的是完整方案验证，尚未形成所有模块的独立消融证据。

四、问题与思考

- (1) 弱类与场景混淆。裸地 IoU 明显低于其他地物。下一步应检查裸地—背景、裸地—农田混淆样本及标注一致性，在验证集上评估定向裁剪与类别重加权，不以测试集反复选择策略。
- (2) 细节与边界评价不足。像素 mIoU 不能完整反映窄道路连通性或车辆实例遗漏。可补充具有明确容差的边界指标及小目标分组评价，并固定评价定义。
- (3) 模块有效性需验证。低秩接口当前同时零初始化上下投影生成参数，双线性乘积可能出现零梯度起点，应专项核验梯度与 `checkpoint` 中的实际激活，再设计单侧非零初始化的独立实验；本报告不将该分支视为已验证收益来源。
- (4) 泛化与效率证据有限。当前 H3 为单种子结果，后续需补齐同协议 **MiT-B3** 基线、多种子复现和按场景分组验证；尚未测得规范的端侧延迟，不声称实时部署能力。原型记忆、在线写入和三视图 TTA 尚未在本文主路径实现，列为后续探索。

五、过程进度

以下按现有日志重建阶段记录。早期工作的完整起止日期未保留，表内据实标注；正式对外提交前可由团队补齐。当前报告不代表已完成比赛平台提交。

阶段	开始时间	结束时间	完成内容
数据准备	早期日期待补充	2026-09-16 已有记录	恢复固定划分，明确有标注训练 / 验证 / 测试与无标注比赛目录；本次核对 6996 张有标注数据。
HyperSeg 基础设计与开发	日期待补充	2026-09-16 前已有实现	MiT-B3 编码、场景条件调制、动态融合、低秩接口及双头监督；训练、测试、导出入口。
骨干增强与运行准备	具体日期待补充	2026-09-18	接入 Swin-L 与通道投影，核验预训练加载并进行运行检查。
H3 正式训练与验证	2026-09-18 16:43	2026-09-19 02:54	完成 160000 次更新，周期验证并保存最佳权重。
独立测试与预测整理	2026-09-19 起	截至 2026-09-20 已有产物	获得 699 张测试指标；本地已有 500 张无标注比赛预测。
报告撰写与提交准备	2026-09-20	2026-09-20	整理技术报告、实验依据与参考资源；团队信息和平台正式提交待完成。

六、团队分工

姓名	角色	负责内容
胡子昊	算法设计	HyperSeg 结构、场景条件模块、损失设计与模型训练。
陈子轩	数据与评价	数据配对、标签与划分核验、模型性能测试与模型训练。

七、解题参考资料

公开文献用于说明编码器和参考对照的技术来源；项目自身实现及实验指标以本地代码、配置和原始日志为准。本文 HyperSeg-UAV 名称指当前项目实现。

7.1 公开技术资料

- [1] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers. NeurIPS, 2021. <https://arxiv.org/abs/2105.15203> 。用于 MiT 层次化编码器背景。
- [2] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV, 2021. <https://arxiv.org/abs/2103.14030>
- [3] Cheng B, Misra I, Schwing A G, et al. Masked-attention Mask Transformer for Universal Image Segmentation. CVPR, 2022. <https://arxiv.org/abs/2112.01527>